

Requerimientos para la configuración del entorno virtual

Table of contents

1	Propósito	2
2	Objetivo del entorno virtual	2
3	Requerimientos funcionales del entorno	3
4	Requerimientos técnicos mínimos	3
4.1	Lenguaje	3
4.2	Bibliotecas Python requeridas	3
4.2.1	Núcleo numérico y tabular	3
4.2.2	Serialización tabular	3
4.2.3	Geoespacial vectorial	3
4.2.4	Geoespacial raster	4
4.2.5	Modelado y análisis auxiliar	4
4.2.6	Modelado probabilístico (<i>según etapa</i>)	4
4.2.7	Visualización auxiliar	4
4.2.8	Workflow	4
4.2.9	Pruebas	4
4.3	Dependencias nativas requeridas	4
5	Requerimientos de instalación	5
5.1	Recomendación general	5
5.2	Requerimiento de aislamiento	5
5.3	Requerimiento de exportación	5
6	Requerimientos para el uso de Parquet	5
7	Requerimientos para Snakemake	6

8	Requerimientos para pytest	6
9	Requerimientos de validación del entorno	6
10	Requerimientos de estructura del proyecto	7
11	Requerimientos de mantenimiento	7
12	Requerimientos de portabilidad	7
13	Criterios de aceptación del entorno virtual	7
14	Recomendación operativa	8

1 Propósito

Este documento define los requerimientos técnicos mínimos para configurar un entorno virtual reproducible y operativo para el workflow de producción del Índice de Integridad Ecosistémica.

Su propósito es servir como guía para:

- preparar estaciones de trabajo;
- definir entornos reproducibles;
- reducir conflictos entre dependencias;
- asegurar que el pipeline pueda ejecutarse de manera consistente.

2 Objetivo del entorno virtual

El entorno virtual debe proporcionar una base controlada para ejecutar un flujo que incluye:

- geoprocésamiento vectorial y raster;
- integración tabular;
- serialización de datos intermedios;
- ejecución orquestada por Snakemake;
- validación automatizada con pytest;
- modelado probabilístico, cuando corresponda;
- generación de productos raster finales.

3 Requerimientos funcionales del entorno

El entorno virtual debe permitir:

1. ejecutar scripts Python desde línea de comandos;
2. importar correctamente bibliotecas numéricas, tabulares y geoespaciales;
3. leer y escribir archivos vectoriales;
4. leer, reproyectar, rasterizar y escribir archivos raster;
5. leer y escribir tablas en Parquet;
6. ejecutar Snakemake;
7. correr pruebas con pytest;
8. soportar, cuando sea necesario, bibliotecas de modelado probabilístico;
9. registrar y reproducir la configuración usada.

4 Requerimientos técnicos mínimos

4.1 Lenguaje

- Python 3.x en una versión estable y soportada por las bibliotecas geoespaciales seleccionadas.

4.2 Bibliotecas Python requeridas

4.2.1 Núcleo numérico y tabular

- numpy
- pandas

4.2.2 Serialización tabular

- pyarrow

4.2.3 Geoespacial vectorial

- geopandas
- shapely
- pyproj
- fiona o pyogrio

4.2.4 Geoespacial raster

- rasterio
- affine

4.2.5 Modelado y análisis auxiliar

- scipy
- scikit-learn

4.2.6 Modelado probabilístico (*según etapa*)

- pgmpy

4.2.7 Visualización auxiliar

- matplotlib

4.2.8 Workflow

- snakemake

4.2.9 Pruebas

- pytest

4.3 Dependencias nativas requeridas

El entorno debe asegurar compatibilidad con bibliotecas del sistema requeridas por el stack geoespacial:

- GDAL
- PROJ
- GEOS

Estas dependencias deben ser consistentes con las versiones de `rasterio`, `geopandas`, `shapely` y `pyproj`.

5 Requerimientos de instalación

5.1 Recomendación general

Se recomienda usar un mecanismo de gestión de entorno que permita controlar bien dependencias geoespaciales. El proyecto puede operar con:

- `venv` + instalación cuidadosa de wheels compatibles, o
- `conda` / `mamba` si se busca más robustez geoespacial.

La decisión depende del contexto operativo del proyecto. Para flujos con muchas dependencias geoespaciales, suele ser conveniente priorizar una estrategia que reduzca conflictos binarios.

5.2 Requerimiento de aislamiento

El entorno del proyecto debe estar aislado de:

- la instalación global de Python;
- otros proyectos con dependencias incompatibles;
- bibliotecas geoespaciales de sistema no controladas por el proyecto, cuando eso pueda generar conflictos.

5.3 Requerimiento de exportación

La configuración del entorno debe poder exportarse en un archivo reproducible, por ejemplo:

- `requirements.txt`
- `pyproject.toml`
- `environment.yml`

6 Requerimientos para el uso de Parquet

Dado que se propone adoptar **Parquet** como tecnología base de serialización tabular, el entorno debe garantizar:

1. disponibilidad de `pyarrow`;
2. lectura y escritura confiable desde `pandas`;
3. capacidad de trabajar con tablas particionadas por región o variable si el workflow evoluciona hacia esa estrategia.

7 Requerimientos para Snakemake

El entorno debe permitir:

- ejecutar reglas locales;
- resolver dependencias entre scripts;
- parametrizar rutas;
- reiniciar pasos fallidos;
- paralelizar ramas cuando sea posible.

Además, la configuración del workflow debe poder convivir con el entorno geoespacial sin romper compatibilidades.

8 Requerimientos para pytest

El entorno debe incluir soporte para correr:

- pruebas unitarias;
- pruebas de integración;
- pruebas smoke del workflow.

Las pruebas deben poder ejecutarse desde línea de comandos sin configuración manual adicional del intérprete.

9 Requerimientos de validación del entorno

Antes de considerar operativo el entorno virtual, debe validarse que puede:

1. importar correctamente `numpy`, `pandas`, `rasterio`, `geopandas`, `pyarrow`, `snakemake` y `pytest`;
2. leer al menos un insumo vectorial;
3. leer al menos un raster;
4. escribir un archivo Parquet;
5. ejecutar una prueba simple con `pytest`;
6. correr al menos una regla mínima de Snakemake.

10 Requerimientos de estructura del proyecto

El entorno debe ser compatible con una estructura de proyecto donde existan al menos:

- scripts Python del workflow;
- reglas Snakemake;
- archivos de configuración;
- carpeta de pruebas;
- carpetas de salida para rasters, tablas y productos finales.

11 Requerimientos de mantenimiento

El proyecto debe definir una práctica de mantenimiento del entorno que incluya:

- actualización controlada de dependencias;
- registro de cambios relevantes de versión;
- revalidación del workflow después de cambios mayores;
- conservación de una configuración estable para corridas formales.

12 Requerimientos de portabilidad

El entorno debe ser portable al menos entre máquinas del equipo con configuración comparable, siempre que:

- exista acceso a las mismas rutas de datos o a una configuración equivalente;
- las dependencias nativas geoespaciales estén correctamente instaladas;
- el archivo de definición del entorno esté disponible.

13 Criterios de aceptación del entorno virtual

El entorno virtual se considerará correctamente configurado si cumple lo siguiente:

1. instala todas las bibliotecas requeridas sin conflictos críticos;
2. permite ejecutar scripts geoespaciales del proyecto;
3. permite leer y escribir Parquet;
4. permite correr Snakemake;
5. permite correr pytest;
6. permite generar un producto raster y un producto tabular mínimo del workflow.

14 Recomendación operativa

Se recomienda mantener este documento alineado con:

- el archivo real de definición del entorno;
- la documentación del workflow;
- la batería de pruebas;
- la evolución de las dependencias geoespaciales y del motor de inferencia.